

PPO 策略头结构改造对比

扁平 6000 维动作头 → 自回归分解双头 | 同超参 · 同 2000 轮训练的单变量对照

1. 决策问题

每步选一个 (作业, 机器) 对

状态 $s_t \in \mathbb{R}^{6690}$

作业特征 3×200 : 完成·最快/平均加工
机器特征 3×30 : 负载·计数·有效
成本矩阵 200×30 : 加工+换型

合法动作 $\leq 200 \times 30 = 6000$
非法动作 masked (-inf)

$a_t = (j, m)$
作业 j 分配到机器 m

- 动作空间随实例规模变化
12 → 6000
- 一个网络 (pad 统一)
服务全部 15 个实例

2. 改造前：扁平动作头

全部 6000 对直接竞争

状态 s_t

MLP 主干
 $6690 \rightarrow 256 \rightarrow 256$

Linear $256 \rightarrow 6000$
6000 维 logits + mask
同一向量读出全部动作对

$a = (j, m)$

$\pi_{old}(a | s) = \text{Cat}(6000 \text{ logits})$

- 6000 对的偏好由同一个
256 维向量线性读出
- 成对相对比较难以表达
- 与逐步最优动作吻合率
7.6% (大实例 0~2%)
- 平均 Cmax/LB = 12.14

瓶颈

3. 改造后：自回归分解

先选作业，再按作业选机器

$\pi(a | s) = \pi(j | s) \cdot \pi(m | s, j)$

状态 s_t

MLP 主干 → 256

Job 头 $256 \rightarrow 200$
选作业 $\pi(j)$ · 掩码已完工

Machine 头 $\oplus [\text{cost_slice}, \text{负载}]$
→ 30 选机器 $\pi(m|j)$

$a = j \times 30 + m$

读该作业成本切片 (30 维)

- 机器头直接读取该作业的
加工+换型成本 (30 维)
- 归纳偏置：先定优先级，
再为该作业选最优机器
- 分解可表示任意联合分布
→ 表达力不降

4. 训练与实现

数学形式与不变量

$\log \pi(a) = \log \pi(j) + \log \pi(m | j)$

联合动作的对数概率 (两段之和)

$\mathcal{H} = \mathcal{H}(j) + \mathbb{E}_{j \sim \pi}[\mathcal{H}(m | j)]$

熵正则：精确作业熵 + MC 估计

$\mathcal{L} = \mathcal{L}^{CLIP} + 0.5 \mathcal{L}^{VF} - \beta \mathcal{H}$

PPO 损失形式不变 (clip $\epsilon=0.2$)

checkpoint 增加 "arch": "factored"
采样 / 贪心推理均改为两段式

- 超参数、 $\gamma=1.0$ 、GAE、
2000 轮全部保持不变
- 严格单变量对照实验

5. 对照实验结果

同预算严格对照

平均 Cmax / 下界

12.14 → 8.62 (+29%)
15 / 15 实例全部改善
最差实例 31.3 → 19.8
小实例 1.19~1.72 ≈ GA

模仿探针诊断

逐步最优作业决策
91% 可从特征线性恢复
→ 信息瓶颈已解除

剩余差距来源

makespan max 结构的
不可逆放大 (一次错位
永久抬高完工时间)
GA 每实例 3.6 万次搜索

- 五方法排名：GA 3.08 <
贪心 3.60 < SPT 4.18 <
PPO 8.62 < 随机 27.7

唯一变量是策略头结构：同等训练预算下 12.14 → 8.62 (+29%)；剩余与 GA 的差距来自 max 不可逆放大与搜索范式差，而非信息瓶颈